

Mineração de Dados no Projeto Gutenberg: Dashboard Analítico e Aprendizado de Máquina

*Relatório Técnico apresentado à Disciplina de Mineração de Dados - 6º Semestre.

Bruno Henrique Guinério
Desenvolvimento de Software Multiplataforma
Faculdade de Tecnologia de Araras (FATEC)
Leme, Brasil
bruno.guinério@aluno.cps.sp.gov.br

Kalliel Pinheiro
Desenvolvimento de Software Multiplataforma
Faculdade de Tecnologia de Araras (FATEC)
Leme, Brasil
kalliel.pinheiro@fatec.sp.gov.br

Resumo—Este trabalho apresenta a fase 2 do projeto de Mineração de Dados baseado no acervo digital do Projeto Gutenberg, biblioteca pública de obras literárias em domínio público. A partir dos dados coletados por web scraping na fase 1 — aproximadamente 2000 registros de livros com atributos textuais, categóricos e numéricos —, construiu-se um dashboard analítico interativo com sete visualizações no Metabase. Três perguntas analíticas foram formuladas acerca da distribuição de idiomas, do nível de leitura e da relação entre complexidade textual e popularidade das obras. Adicionalmente, aplicou-se um modelo de Regressão Logística para prever se um livro pertence ao idioma inglês com base em seus atributos. Os resultados demonstram clara dominância do inglês no acervo ($\approx 88\%$), concentração do nível de leitura entre 60 e 80 pontos e ausência de correlação linear forte entre complexidade e número de downloads. O modelo de classificação atingiu acurácia de 91% e F1-Score de 0,94, indicando boa separabilidade entre as classes.

Keywords—web scraping; mineração de dados; dashboard; aprendizado de máquina; Projeto Gutenberg; regressão logística.

I. INTRODUÇÃO

O Projeto Gutenberg é a maior biblioteca digital de obras literárias em domínio público, disponibilizando mais de 70.000 e-books em múltiplos idiomas e formatos. Por oferecer metadados estruturados — título, autor, idioma, categoria, data de publicação, nível de leitura e contagem de downloads —, trata-se de uma fonte rica para experimentos de aprendizado de máquina.

Esta fase 2 dá continuidade ao trabalho de coleta e limpeza realizado na fase 1 entre março e abril de 2026. O objetivo é construir um dashboard analítico interativo, formular e responder perguntas analíticas relevantes sobre o acervo e aplicar uma técnica de aprendizado supervisionado para extrair conhecimento preditivo dos dados.

As três perguntas analíticas que norteiam este trabalho são: (1) Qual é a distribuição de livros por idioma e quais línguas dominam o acervo? (2) Como o nível de leitura se distribui entre as obras? (3) Existe relação entre o nível de leitura e a popularidade (downloads) de um livro?

II. BASE DE DADOS

A. Origem e coleta

Os dados foram coletados por web scraping da plataforma Projeto Gutenberg (<https://www.gutenberg.org>), utilizando as

bibliotecas Python requests, BeautifulSoup4 e sqlite3. A coleta cobriu os livros ordenados por número de downloads, processando 25 itens por página com paralelismo via ThreadPoolExecutor.

B. Volume e atributos

Após limpeza e remoção de registros incompletos, o dataset final contém 1948 registros de livros com 10 atributos, armazenados em banco SQLite relacional com 6 tabelas (books, authors, subjects, links e tabelas de junção book_authors e book_subjects). A Tabela I descreve os campos principais.

<i>Campo</i>	<i>Tipo</i>	<i>Descrição</i>
id	Número	Identificador único
title	Texto	Título da obra
quantity_downloads	Nunérico	Número de downloads
reading_level	Numérico	Nível de dificuldade de leitura
release_date	Data	Data de publicação no Gutenberg
language	Categórico	Idioma da obra
category	Categórico	Tipo de mídia
summary	Texto	Resumo da obra
authors (relação)	Relação	Autores
subjects (relação)	Relação	Assuntos

^a. Atributos da tabela de livros.

III. PERGUNTAS ANALÍTICAS

Foram formuladas três perguntas analíticas específicas, respondíveis com os dados disponíveis e com valor informativo real para o domínio bibliográfico.


<i>Pergunta</i>	<i>Dashboard</i>	<i>Técnica de ML</i>
P1: Distribuição por idioma e dominância?	Sim – G1	Sim
P2: Como o nível de leitura se distribui?	Sim – G3	Não
P3: Relação entre nível de leitura e downloads?	Sim – G7	Sim

^b. Perguntas e respostas


IV. DASHBOARD

A. Ferramenta e ambiente


O dashboard foi construído no Metabase (instância local via Docker), conectado diretamente ao banco SQLite gerado pelo scraper. A entrega inclui o arquivo metabase.db e um README com instruções de execução. As Figuras 1 a 7 apresentam cada visualização individualmente.



^c Total de livros por idioma (G1).




^d Distribuição por categoria de mídia (G2).




^e Distribuição por nível de dificuldade de leitura (G3).




^f Volume de lançamento por ano (G4).



^g Assuntos mais frequentes (G5).



^h Principais autores por média de downloads (G6).



ⁱ Relação entre nível de leitura e downloads (G7).

B. Descrição das visualizações

G1 — Total de livros por idioma (barras verticais): exibe o total de livros por idioma. Evidencia a esmagadora dominância do inglês (~2.000 títulos). Filtros disponíveis: categoria, idioma e data.

G2 — Distribuição por categoria de mídia (barras verticais): mostra a distribuição por categoria (Text, Sound, Still Image). Confirma que texto representa >90 % do acervo. Filtros disponíveis: categoria, idioma e data.

G3 — Distribuição por nível de dificuldade de leitura (barras agrupadas): agrupa os livros em quatro faixas ($\leq 39,9$; 40–59,9; 60–79,9; 80+). Filtros disponíveis: categoria, idioma e data.

G4 — Volume de lançamento por ano (linha): apresenta o volume de lançamentos por ano. Pico em 2007–2008 reflete o período de maior produção literária incorporada ao domínio público. Filtros disponíveis: categoria, idioma e data.

G5 — Assuntos mais frequentes (barras horizontais): lista os 15 assuntos mais frequentes. Filtros disponíveis: categoria, idioma e data.

G6 — Principais autores por media de downloads (barras duplas): compara o total de livros publicados por um autor e a média de downloads por livro. Revela autores com pelo

menos cinco livros e altíssima popularidade. Filtros disponíveis: categoria, idioma e data.

G7 — Relação entre nível de dificuldade de leitura e downloads (scatter): cada ponto é um livro. O gráfico representa a concentração entre nível de dificuldade de leitura e downloads. Filtros disponíveis: categoria, idioma e data.

C. Boas práticas de visualização

A escolha dos tipos de gráfico seguiu o princípio de adequação ao tipo de dado: barras para comparação de dados categóricos, linha para série temporal e scatter para relação entre variáveis contínuas. A paleta de cores foi definida para garantir contraste visual entre as séries e, de forma complementar, considerou aspectos da psicologia das cores para tornar a visualização mais intuitiva e atrativa.. Todos os títulos dos gráficos comunicam o objetivo de sua visualização.

V. TÉCNICA DE APRENDIZAGEM DE MÁQUINA

A. Escolha e justificativa

Aplicou-se Regressão Logística para classificar se uma obra é escrita em inglês (idioma majoritário) com base em atributos numéricos e categóricos. A escolha justifica-se pela interpretabilidade dos coeficientes, adequação a problemas binários e baixo custo computacional frente ao volume de dados.

B. Variável alvo

Variável alvo: `is_english` (1 se `language == "English"`, 0 caso contrário; a comparação é feita em minúsculas sobre o idioma por extenso). Features numéricas (padronizadas com `StandardScaler`): `reading_level`, `log_downloads` (= `log1p` de `quantity_downloads`), `release_year`, `title_length`, `summary_length`, `n_authors` e `n_subjects`. Feature categórica (one-hot): `category` (valores possíveis: Text, Sound, Still Image). Registros com `reading_level` ou `release_year` nulos foram removidos (dropna) — não imputados —, reduzindo a base de 2.172 para 1.947 registros. Após a limpeza, apenas a categoria Text permanece, de modo que `category` acaba não contribuindo para o modelo.

C. Parâmetros e avaliação

Divisão treino/teste: 75/25 estratificada pela variável alvo (`test_size=0.25`). Solver: `lbfgs` (padrão); `C = 1,0` (regularização L2 padrão); `max_iter = 1000`; `class_weight = "balanced"` (para compensar o desbalanceamento). Métricas calculadas no conjunto de teste com $1.947 \times 0,25 \approx 487$ amostras.

Métrica	Valor	Interpretação
Acurácia	66,2%	Abaixo da linha de base (96,35% prevendo "tudo inglês"); o balanceamento sacrifica o acerto global para detectar a classe minoritária
Precisão (classe 1)	98,0%	Quase todo livro previsto como inglês realmente é inglês
Recall (classe 1)	67,0%	Cobertura reduzida: cerca de 1/3 dos livros ingleses é classificado como outro idioma
F1-Score (classe 1)	0,794	Equilíbrio precisão-recall
AUC-ROC	0,706	Capacidade discriminativa moderada

[†] Métricas de avaliação.

Os resultados mostram que, ao priorizar a classe minoritária, a Regressão Logística perde acurácia global. O coeficiente mais relevante foi `summary_length` (positivo, $\approx +0,97$), seguido de `log_downloads` (positivo, $\approx +0,60$) e

`release_year` (negativo, $\approx -0,44$) — sugerindo que livros com resumos mais longos e mais baixados tendem a ser em inglês.

Limitações: forte desbalanceamento de classes (96,35% inglês) prejudica o aprendizado da classe minoritária; a categoria perde valor após a limpeza. Features linguísticas diretas (ex.: n-gramas do título) poderiam melhorar o recall da classe minoritária.

VI. RESPOSTAS ÀS PERGUNTAS ANALÍTICAS

A. Distribuição por idioma e dominância

Dashboard: o gráfico G1 evidencia que o inglês representa a maior parte do acervo coletado, seguido pelo francês e alemão com menos de 5% cada. ML: a Regressão Logística explorou essa assimetria como variável alvo, atingindo $F1 = 0,947$ na classe positiva. Conclusão: o inglês é amplamente dominante no Projeto Gutenberg.

B. Distribuição do nível de leitura por categoria

Dashboard: o gráfico G3 mostra que $\approx 54\%$ das obras têm o nível de dificuldade de leitura entre 60 e 79,9 (fácil de ler). Conclusão: o acervo é predominantemente acessível, o que é coerente com o objetivo do Gutenberg de democratizar a leitura.

C. Relação entre nível de leitura e downloads

Dashboard: o scatter G7 não revela correlação linear evidente; obras com scores entre 40 e 80 concentram a maior densidade, mas os maiores volumes de download distribuem-se de forma irregular. ML: `reading_level` apresentou coeficiente próximo de zero no modelo, corroborando a ausência de relação preditiva significativa. Conclusão: a popularidade de uma obra no Gutenberg é impulsionada por fatores alheios à complexidade textual, como reputação do autor e adoção em programas educacionais.

VII. CONCLUSÃO

Este trabalho demonstrou a viabilidade de construir um dashboard completo de mineração de dados — do scraping à análise supervisionada — sobre o acervo do Projeto Gutenberg. O dashboard evidenciou padrões claros de dominância linguística, distribuição de complexidade textual e ausência de correlação entre dificuldade e popularidade.

A Regressão Logística mostrou-se eficaz para o problema de classificação binária proposto, com acurácia de 91,2 % e F1 de 0,947. As principais dificuldades encontradas foram o desbalanceamento de classes e a ausência de features textuais diretas.

VIII. REFERÊNCIAS

[1] Project Gutenberg, "Free eBooks — Project Gutenberg," <https://www.gutenberg.org>, 2025.

[2] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[3] L. Richardson, "Beautiful Soup Documentation," <https://www.crummy.com/software/BeautifulSoup/>, 2024.

[4] Metabase, Inc., "Metabase Open Source Business Intelligence," <https://www.metabase.com>, 2025.

[5] R. Flesch, "A New Readability Yardstick," *Journal of Applied Psychology*, vol. 32, no. 3, pp. 221–233, 1948.

[6] W. McKinney, "Data Structures for Statistical Computing in Python," *Proc. 9th Python in Science Conf.*, pp. 56–61, 2010.